

Informe Tecnico: Analisis y modelado de transacciones de supermercado/ Sistema supermercado

Andrés Arango

Link del repositorio del proyecto: <https://github.com/arango850/sistemaSupermercado>

Descripción de los datos

Fuente y estructura

El conjunto de datos utilizado corresponde a transacciones de un supermercado distribuidos en 4 archivos CSV. Cada uno de estos representa una tienda. Estos se representan de la siguiente manera:

Archivo	Tienda	Transacciones
102_Tran.csv	102	314286
103_Tran.csv	103	407,130
107_Tran.csv	107	254,633
110_Tran.csv	110	132,938
Total		1,108,987

Cada registro representa un ítem dentro de una transacción y fue transformado para obtener las siguientes columnas:

Campo	Tipo de variable	Descripción
Tran_id	Entero	Identificador único de la transacción
Date	Fecha	Fecha de la compra
Client_id	Entero	Identificador del cliente
Product_id	Entero	Identificador del producto
Category_id	Entero	Identificador de la categoría del producto
Category_name	Texto	Nombre de la categoría
Quantity	Entero	Cantidad de unidades compradas
Store_id	Entero	Tienda donde se realizó la compra

Alcance de los datos

Los datos encontrados dentro de la base de datos proporcionaron la siguiente información:

Registros totales (ítem x transacción)	10,591,793
Transacciones únicas	1,108,987
Clientes únicos	131,186
Categorías de productos únicas	449

Grupos de categorías	50
Tiendas	4
Período	01/01/2013 al 30/06/2013

Calidad de los datos


- No se encontraron valores nulos en los valores clave de los archivos CSV
- Las fechas cubren un rango continuo de 181 días

Variables derivadas

De los datos obtenidos, se construyeron las siguientes métricas por cliente:

Variable	Descripción
Purchase_frequency	Número de transacciones totales del cliente
Total_units	Suma de unidades compradas
Avg_basket_size	Promedio de ítems distintos por transacción
Avg_categories_per_txn	Promedio de categorías por transacción
Category_diversity	Número de categorías únicas compradas
Num_stores_visited	Cantidad de tiendas distintas visitadas
Active_days	Número de días distintos en que compró

Arquitectura de la solución



Tecnologías utilizadas

Capa	Tecnología
Frontend	React + Vite
Backend	Django, Django REST Framework
Pipeline Local	Pandas, Scikit-learn, mlxtend
Pipeline Spark	PySpark, Java 17
Comunicación	API REST + JSON

Metodología de análisis

Resumen ejecutivo

Se calcularon los siguientes KPI's directamente del dataset consolidado:

- Total de unidades vendidas: suma de quantity sobre todos los registros
- Número de transacciones: conteo de tran_id únicos
- Top 10 productos: categorías con mayor volumen acumulado de unidades.
- Top 10 clientes: Clientes con mayor purchase_frequency
- Días pico: Días con mayor conteo de transacciones (serie de tiempo diaria)
- Categorías más frecuentes: Participación relativa de cada categoría en el total de transacciones.

Visualizaciones analíticas

Visualizacion	Metodo	Variables
Serie de tiempo	Agrupación por día/ semana/ mes	Date, quantity
Boxplot	Distribución por categoría	Total_units por category_name
Heatmap	Correlación de pearson	7 variables de comportamiento por cliente

Segmentación/ K-means

1. Features engineering: Las 7 variables derivadas fueron escaladas con StandarScaler para evitar que total_units domine el resultado.
2. Selección de k: Se evaluaron los k de 3,4,5,6 usando la métrica Silhoutte Score (Mayor = mejor separación entre clusters)
3. Resultado: El k de 4 fue seleccionado dado su silhoutte de 0.6786
4. Etiquetas: Los segmentos fueron interpretados y etiquetados según las medianas de cada variable.

Recomendaciones/Reglas de asociación

Se construye una matriz de co-ocurrencia a nivel de canasta: para cada par de categorías que aparecen en la misma transacción se calcula

$$support(A) = \frac{|Transacciones\ que\ contiene\ A|}{|Transacciones\ totales|}$$

$$confidence(A \rightarrow B) = \frac{support(A \cup B)}{support(A)}$$

$$lift(A \rightarrow B) = \frac{confidence(A \rightarrow B)}{support(B)}$$

Se definieron los siguientes umbrales para dar recomendaciones con cierto valor:

Min_support = 5%

Min_confidence = 30%

Min_lift = 1.0

Recomendaciones por cliente

1. Se determina el segmento del cliente consultando clients_segments.json
2. Se recuperan las top 10 categorías del segmento
3. Se filtran las reglas cuyo antecedente esté en esas categorías y cuyo consecuente no haya sido comprado recientemente.
4. Se ordenan por lift y se retornan las 20 mejores.


Principales hallazgos visuales

Resumen ejecutivo




Se pudo encontrar un total de:

- 10,591,793 unidades vendidas.
- 1,108,987 Transacciones
- 131,186 clientes
- 449 categorías de productos
- 4 tiendas
- Registros desde el 1/01/2013 al 30/06/2013




La categoría de producto más vendida fue PANES-TOSTADAS con 300.526 unidades vendidas, la segunda fue LECHE LIQUIDA con 290.313 unidades vendidas, la tercera categoría más vendida fue VERDURAS DE FRUTOS con 269.855 unidades vendidas.



El cliente con más transacciones fue el cliente con el identificador 336266, con un total de 535 transacciones, el segundo cliente con más transacciones fue el cliente con el


identificador 440157 con 163 transacciones, el tercer cliente con más transacciones fue el cliente con identificador 806377 con 159 transacciones.

Unidades Vendidas por Tienda



La tienda con más unidades vendidas o con más actividad fue la tienda 103, dado que tuvo un total de 4,234,392 unidades vendidas, la tienda con menor ventas fue a tienda 110, que tuvo un total de 1,384,106 unidades vendidas.

Distribución por Categoría (Top 9 + Otros)



A pesar de que categorías como PANES-TOSTADAS, LECHE LÍQUIDA, VERDURAS DE FRUTOS, fueron las que más unidades vendidas tuvieron, el 78,3% de las unidades vendidas correspondieron a categorías fuera del top presentado anteriormente.

Actividad Semanal (transacciones por mes x día de semana)

Mes	Lun	Mar	Mié	Jue	Vie	Sáb	Dom
2013-01	23.205	26.858	28.502	31.275	21.580	26.782	26.714
2013-02	21.625	22.869	19.809	24.919	21.243	28.850	31.456
2013-03	22.121	22.882	21.255	25.099	25.461	35.841	36.654
2013-04	27.393	30.089	20.329	24.124	20.183	27.990	32.614
2013-05	22.680	23.783	26.397	29.596	27.554	29.904	28.285
2013-06	25.511	24.258	20.953	23.753	23.350	39.648	35.683

Los días donde más hubo actividad en todos los supermercados fueron los días sábado y domingo, los meses donde hubo mas actividad fueron marzo y junio.


Días Pico (Top 10 por transacciones)


#	Fecha	Transacciones
1	2013-06-15	9476
2	2013-05-11	8854
3	2013-02-03	8523
4	2013-03-03	8426
5	2013-06-01	8420
6	2013-04-28	8286
7	2013-04-07	8265
8	2013-03-02	8160
9	2013-06-29	8156
10	2013-04-21	8126

El día con más transacciones fue el 15 de junio del 2013 con 9476 transacciones.

Serie de tiempo


Serie Temporal de Actividad





Se observa que a medida que el tiempo pasa la actividad dentro de los supermercados aumenta, también se ve que a lo largo de la semana se presentan picos en los días correspondientes a fines de semana y bajones en los días posteriores a estos.

Todas las tiendas tienen un comportamiento similar a lo largo el tiempo, también las tiendas tienen diferencias con respecto al número de transacciones hechas a lo largo del tiempo, siendo la tienda 103 la que tuvo más transacciones y siendo superior a las demás.



Se observa que las transacciones más frecuentes consisten de comprar pocos ítems, dado que de todas las transacciones el 25% contienen al menos 3 ítems, el 50% contienen 6 ítems, el 75% 12 ítems y la transacción más grande fue de 128 ítems.

Heatmap de correlación



- purchase_frequency y active_days presentan la correlación más alta ($r \approx 1$), lo que indica que los clientes frecuentes son también los más constantes en el tiempo.
- category_diversity correlaciona moderadamente con avg_basket_size, sugiriendo que cestas más grandes tienden a ser más diversas.

- num_stores_visited muestra baja correlación con el resto, indicando que la fidelidad a una tienda no está relacionada con el volumen de compras.

Resultado del modelo de segmentación y recomendación

Segementación K-means

K evaluado	Inercia	Silhoutte
3	236,216	0.6343
4	187,813	0.6786
5	156,815	0.6009
6	137,463	0.6046



Descripción de los 4 segmentos

Segmento	Etiqueta	Característica Principal
0	Compradores Esporádicos	Baja frecuencia, baja diversidad
1	Compradores regulares	Frecuencia media, cesta diversa
2	Compradores frecuentes	Alta frecuencia, Alta diversidad
3	Compradores diversos	Volumen muy alto, multi tienda

Reglas de asociación

Resultados globales

Transacciones analizadas: 1,108,987


Umbrales: support $\geq$ 5% | confidence $\geq$ 30%

Total de reglas: 395

Categorías con reglas: 36

Top 15 Reglas por Lift

Lift = qué tan más probable es comprar B si ya compraste A, comparado con la probabilidad base de B



Un lift > 2 indica que la compra conjunta de A y B es al menos el doble de probable que si fueran independientes, lo que confirma una asociación real de comportamiento de compra.

Recomendaciones por cliente

[Por Categoría](#) [Por Cliente](#)

Recomendaciones personalizadas por cliente

Ingresa un ID de cliente para obtener sugerencias basadas en su segmento de compra

ID de Cliente: Buscar cliente

IDs válidos: entre 1 y 131,186 aproximadamente

SEGMENTO 1
Compradores Esporádicos

Categorías más compradas por este segmento:
QUESO PANES-TOSTADAS VERDURAS DE FRUTOS CUIDADO DE LA COCINA VERDURAS RAIZ, TUBERCULO Y BULBOS

Recomendaciones personalizadas

Categorías que clientes similares compran junto a sus categorías habituales

#	Si compra...	También podría comprar	Confianza	Lift
1	CUIDADO DE LA ROPA	PASTAS COMESTIBLES	30.8%	2.80x
2	VERDURAS DE FRUTOS	VERDURAS RAIZ, TUBE, ETC, PESO FIJO	30.2%	2.71x
3	VERDURAS DE FRUTOS	AROMATICAS CONDIMENTOS	34.4%	2.69x
4	PASABOCAS	PAPEL HIGIENICO	30.4%	2.57x
5	CUIDADO DE LA COCINA	CUIDADO DE PISOS	30.1%	2.49x
6	CUIDADO DE LA ROPA	JUGOS	36.1%	2.40x
7	CUIDADO DE LA COCINA	AZUCAR	31.0%	2.36x

El sistema permite consultar cualquier cliente por su ID y obtener:

1. Su segmento de pertenencia y etiqueta descriptiva.
2. Las categorías típicas del segmento.
3. Hasta 20 recomendaciones personalizadas ordenadas por lift.

Conclusiones y posibles aplicaciones empresariales

Conclusiones

- El análisis de co-ocurrencia y FP-Growth producen resultados equivalentes con los mismos umbrales (support 5%, confidence 30%), lo que valida la consistencia metodológica entre ambos pipelines.
- La segmentación k=4 con silhouette=0.6786 es estadísticamente sólida. Un silhouette por encima de 0.5 se considera una separación de clusters

razonablemente buena. Los 4 grupos capturan perfiles de cliente claramente distintos en términos de frecuencia y diversidad.

- La ausencia de datos de precio no limita la capacidad analítica. Las métricas derivadas (diversidad, frecuencia, tamaño de cesta) son suficientes para construir modelos de segmentación y recomendación funcionales.
- La incorporación de nuevos datos es inmediata: basta añadir archivos CSV adicionales en DataSet/Transactions/ y hacer clic en "Actualizar análisis" desde la UI para regenerar todos los resultados.

Posibles aplicaciones empresariales

Aplicación	Descripción	Módulo
Marketing segmentado	Enviar promociones diferenciadas por segmento de cliente (email, app)	Segmentación
Venta cruzada en caja	Sugerir al cajero o pantalla de autoservicio productos relacionados en tiempo real	Recomendaciones por cliente
Gestión de inventario	Anticipar demanda de categorías co-compradas para optimizar stock	Reglas de asociación
Layout de tienda	Ubicar físicamente juntas las categorías con mayor lift para aumentar ventas impulsivas	Top reglas locales
Detección de clientes en riesgo	Clientes del segmento de alta frecuencia que no han comprado en N días	Segmentación + serie de tiempo
Análisis multi-tienda	Comparar perfiles de clientes y top categorías por tienda para decisiones de localización	Resumen ejecutivo